



Universidad Austral de Chile

Facultad de Ciencias de la Ingeniería
Escuela de Ingeniería Civil en Informática

INTEGRACIÓN DE DATOS Y RESILIENCIA COMUNITARIA EN DIMENSIONES SOCIOCOMUNITARIAS E INSTITUCIONALES

Proyecto para optar al título de
Ingeniero Civil en Informática

PROFESOR PATROCINANTE:
CRISTIAN OLIVARES-RODRÍGUEZ
INGENIERO CIVIL INFORMÁTICO
MASTER EN VISIÓN POR COMPUTADORA E INTELIGENCIA ARTIFICIAL
DOCTOR EN INGENIERÍA

ESTEBAN NICOLÁS TEJEDA WEBAR
VALDIVIA – CHILE
2025

DEDICATORIA

AGRADECIMIENTOS

ÍNDICE

Dedicatoria	I
Agradecimientos	II
Resumen	VIII
Abstract	IX
1. INTRODUCCIÓN	1
1.1. Resiliencia comunitaria	1
1.2. Modelo CORE	2
1.3. Descripción del proyecto	2
1.3.1. Estado del arte	3
1.3.2. Descripción de la innovación	3
1.3.3. Impacto del proyecto	4
1.4. Objetivos	4
1.4.1. Objetivo general	4
1.4.2. Objetivos específicos	4
2. MARCO TEÓRICO	5
2.1. Objetivo y pregunta de revisión	5
2.2. Método de revisión	5
2.3. Fuentes y estrategias de búsquedas	5
2.4. Cadena de búsquedas	6
2.5. Criterios de selección	6
2.6. Extracción de la información	6
2.7. Estudios incluidos y excluidos	6
2.8. Información extraída general	7
2.9. Principales hallazgos y factores claves	8
3. VIABILIDAD DE INDICADORES	11
3.1. Population Poverty (PP)	11
3.2. Social Capital – Civic Participation (SCCP)	12
3.3. Social Capital – Civic Organizations (SCCO)	12
3.4. Social Capital – Emergency Organizations (SCEO)	12
3.5. Tsunami Drills	13
3.6. Special Needs Population (SNP)	13
3.7. Conclusiones del análisis de viabilidad	14
4. HERRAMIENTAS DE DESARROLLO	15
4.1. Lenguaje de programación	15

4.2.	Base de datos	15
4.3.	Entorno de ejecución	16
4.3.1.	Librerías principales	16
4.3.2.	Librerías secundarias	17
4.4.	Contenedores	17
4.5.	Visualización de datos	18
4.6.	Sistema de control de versiones	18
5.	DISEÑO DE PROTOTIPO	19
6.	DESARROLLO E IMPLEMENTACIÓN	23
6.1.	Arquitectura general	23
6.2.	Patrones de diseño	23
6.2.1.	Patrón Builder	23
6.2.2.	Patrón Adapter	24
6.2.3.	Patrón Factory y Singleton	24
6.2.4.	Clase abstracta ScrapeBase	25
6.3.	Tipos de conexión implementados	25
6.4.	Módulos implementados	26
6.4.1.	Módulo emergencias-desastres	26
6.4.2.	Módulo biblioteca-congreso-nacional	26
6.5.	Manejo de errores	27
6.6.	Automatización	27
6.7.	API REST	28
6.8.	Testing	28
6.9.	Volatilidad de las fuentes web	29
7.	RESULTADOS	31
7.1.	Datos extraídos	31
7.1.1.	Tsunami Drills	31
7.1.2.	Resultados calculados de Tsunami Drills	31
7.1.3.	Tasa de Pobreza por Ingresos	32
7.1.4.	Organizaciones Comunitarias	32
7.2.	Validación de la extracción	33
7.3.	Evitación de duplicados	33
7.4.	Ejecución automatizada	34
8.	CONCLUSIONES	35
8.1.	Conclusiones generales	35
8.2.	Conclusiones por objetivo	35
8.2.1.	Objetivo Específico 1	35
8.2.2.	Objetivo Específico 2	36
8.2.3.	Objetivo Específico 3	36
8.3.	Limitaciones	36

8.4. Trabajo futuro	37
REFERENCIAS	39
A. Indicadores del modelo CORE	40

ÍNDICE DE TABLAS

1.	Resumen de la información extraída por artículo	7
2.	Resumen de la investigación sobre Population Poverty	11
3.	Resumen de la investigación sobre Civic Participation	12
4.	Resumen de la investigación sobre Civic Organizations	12
5.	Resumen de la investigación sobre Tsunami Drills	13
6.	Resumen de la investigación sobre Special Needs Population	14
7.	Tipos de conexión implementados en los módulos	25
8.	<i>Adapters</i> disponibles para futuros módulos	26
9.	<i>Endpoints</i> de la API REST	28
10.	Registros extraídos por indicador de simulacros	31
11.	Resultados calculados por indicador de simulacros	32
12.	Datos extraídos de tasa de pobreza por ingresos	32

ÍNDICE DE FIGURAS

1.	Número de artículos por año	7
2.	Cantidad de veces que se analizó cada dimensión en las investigaciones .	9
3.	Cantidad de indicadores totales por dimensión	9
4.	Promedio de indicadores por aparición de dimensión en los artículos . . .	10
5.	Información sociocomunitaria sobre tasa de pobreza en el año 2017 . . .	20
6.	Información sociocomunitaria sobre población carente de servicios básicos y hogares hacinados en el año 2018	21
7.	<i>Interface</i> para la información de la página web	21
8.	<i>Interface</i> para tasa de pobreza	22
9.	<i>Interface</i> para población carente de servicios básicos y hogares hacinados	22
10.	Lista de clases utilizadas para la extracción de la información	22
11.	Diagrama de arquitectura general del sistema mostrando las tres capas: core, módulos y API	23
12.	Ejemplo de configuración de un indicador mediante el <i>IndicatorBuilder</i> .	24
13.	Diagrama de clases de los <i>adapters</i> con sus métodos abstractos	24
14.	Diagrama de secuencia del flujo ETL completo	25
15.	Ejemplo de los datos extraídos por el módulo emergencias-desastres en formato JSON	26
16.	Ejemplo de los datos extraídos por cada sub-indicador del módulo BCN .	27
17.	Colección Bruno con los <i>endpoints</i> documentados	28
18.	Registros extraídos de simulacros-2021 mostrando fecha, tipo y ciudad . .	31
19.	<i>Dashboard</i> de Metabase con el gráfico de barras de simulacros por año . .	32
20.	<i>Dashboard</i> de Metabase con el gráfico comparativo de pobreza CASEN 2017 vs CASEN 2022	32
21.	<i>Dashboard</i> de Metabase con el gráfico de línea temporal de organizaciones comunitarias	33
22.	Indicadores de la dimensión social del modelo CORE	40

RESUMEN

La presente tesis aborda la sistematización del proceso de captura de indicadores cuantitativos sociocomunitarios e institucionales mediante la extracción automatizada de datos de la web, con el objetivo de alimentar el modelo CORE de resiliencia comunitaria ante tsunamis en zonas costeras de Chile.

Se desarrolló un sistema de extracción, transformación y carga (ETL) basado en una arquitectura modular de *adapters* intercambiables, implementado en TypeScript con Node.js y MongoDB. El sistema permite agregar nuevos indicadores y fuentes de datos sin modificar la lógica central, soportando múltiples tipos de conexión: *web scraping* de HTML, extracción de tablas y consumo de APIs JSON.

Se implementaron cinco indicadores distribuidos en dos módulos: simulacros de emergencia (dimensión institucional) y tasa de pobreza junto con organizaciones comunitarias (dimensión sociocomunitaria). El sistema extrajo un total de 29 registros de simulacros, datos de pobreza a nivel comunal, regional y nacional, y 17 registros históricos de organizaciones comunitarias. Los datos fueron validados contra extracciones manuales y se verificó el correcto funcionamiento de los mecanismos de evitación de duplicados.

Los resultados se disponibilizan mediante una API REST y *dashboards* en Metabase, permitiendo al equipo de investigación consultar los indicadores de forma directa sin procesamiento manual.

Palabras clave: resiliencia comunitaria, ETL, *web scraping*, modelo CORE, indicadores sociocomunitarios, TypeScript.

ABSTRACT

This thesis addresses the systematization of the process of capturing quantitative socio-community and institutional indicators through automated web data extraction, aiming to feed the CORE community resilience model for tsunami-prone coastal areas in Chile.

An extraction, transformation, and loading (ETL) system was developed based on a modular architecture of interchangeable adapters, implemented in TypeScript with Node.js and MongoDB. The system allows adding new indicators and data sources without modifying the core logic, supporting multiple connection types: HTML web scraping, table extraction, and JSON API consumption.

Five indicators were implemented across two modules: emergency drills (institutional dimension) and poverty rate together with community organizations (socio-community dimension). The system extracted a total of 29 drill records, poverty data at municipal, regional, and national levels, and 17 historical records of community organizations. The data was validated against manual extractions and the correct functioning of duplicate avoidance mechanisms was verified.

Results are made available through a REST API and Metabase dashboards, allowing the research team to query indicators directly without manual processing.

Keywords: community resilience, ETL, web scraping, CORE model, socio-community indicators, TypeScript.

1. INTRODUCCIÓN

La ubicación geográfica de Chile, situado principalmente entre las placas tectónicas de Nazca y Sudamérica, determina una alta actividad sísmica en el país. A esto se suma la presencia de fallas geológicas, actividad volcánica y efectos de geología local, los cuales pueden provocar desde incendios y erupciones, hasta numerosos sismos y tsunamis.

Uno de los desastres naturales más recordados sigue siendo el “27F”, en el cual un tsunami impactó las costas chilenas, destruyendo localidades y arrasando con poblados enteros. Incluso a día de hoy, no se puede calcular con exactitud la cantidad de fallecidos en el acontecimiento recién descrito.

Con lo anterior como antecedente, se debe agregar que no es posible predecir un desastre natural como un terremoto. Aún así, si bien no se puede saber cuándo ocurrirá, sí se puede tener una idea de cómo actuará la población afectada y el cómo estos pueden sobreponerse a situaciones de adversidad de esta índole.

1.1. Resiliencia comunitaria

Una de las maneras de afrontar esta problemática es utilizando un modelo de resiliencia comunitaria. Si bien no existe una definición específica que logre englobar todo lo que este representa, se utiliza la siguiente definición: “La resiliencia comunitaria se refiere por lo tanto a la capacidad del sistema social y de las instituciones para hacer frente a las adversidades y para reorganizarse posteriormente de modo que mejoren sus funciones, su estructura y su identidad” (Maguire & Cartwright, 2008).

Las diversas investigaciones en el área de la resiliencia comunitaria han dado origen a los llamados “Modelos de resiliencia comunitaria”. Estos modelos varían según el área geográfica, el tipo de comunidad, el comportamiento de las poblaciones y el enfoque que se quiera dar a la investigación.

Cada modelo de resiliencia comunitaria se basa en el cálculo de distintas dimensiones, y a su vez, en cada dimensión se encuentra una diversa variedad de indicadores. Estos indicadores permiten medir los cambios de la resiliencia comunitaria y varían según el modelo que se esté aplicando.

Por lo tanto, algunos estudios afirman que el uso de un modelo de resiliencia comunitaria puede mejorar la preparación, respuesta y recuperación ante desastres a nivel comunitario

en un corto plazo, y entregar una mejor adaptación a largo plazo (Cutter et al., 2014). Si bien existen muchos modelos que atienden a determinadas poblaciones específicas, el modelo que se utiliza en este proyecto es el modelo CORE.

1.2. Modelo CORE

El modelo CORE es un modelo de resiliencia comunitaria que está centrado en las costas chilenas, utiliza dimensiones físicas, ambientales y sociales donde se encuentran veintidós indicadores.

Su iniciativa nace, tal como indica Villagra et al. (2017), debido a la información sobre los indicadores que permiten a las ciudades enfrentar y adaptarse mejor a los impactos de los tsunamis, siendo esta información especialmente escasa para los países en desarrollo como Chile.

Este modelo permite evaluar el riesgo que presentan las áreas costeras susceptibles de ser afectadas por tsunamis, y con base en ello prevenir accidentes y desastres, además de mitigar las posibles consecuencias negativas con el fin de que la población se enfrente de mejor manera a dichos eventos.

Dado que el modelo CORE requiere la obtención y procesamiento de múltiples indicadores, resulta necesario contar con herramientas que automaticen este proceso. A continuación se describe el proyecto desarrollado con este fin.

1.3. Descripción del proyecto

Como se mencionó anteriormente, para el cálculo de la resiliencia comunitaria es necesario obtener la información de distintas dimensiones, las cuales a su vez requieren de diversos indicadores. Cada uno de estos indicadores posee un gran volumen de datos que debe ser descargado, transformado y calculado.

Hasta ahora, cuando se desea calcular la resiliencia comunitaria, los investigadores consumen gran parte de su tiempo en buscar manualmente dentro de diversas fuentes de internet la ubicación de esta información; ya sea en páginas web que entreguen bases de datos ya establecidas, o en la búsqueda de artículos que tengan información posiblemente relevante.

1.3.1. Estado del arte

Actualmente no existe una solución real a esta problemática. Todas las investigaciones de las que se tiene registro realizan el cálculo de la resiliencia comunitaria con una extracción manual de la información para luego ser ingresadas y analizadas con diversos programas estadísticos como SPSS y R.

En la investigación realizada por Cutter et al. (2014), el cual utiliza el modelo BRIC que está centrado en la geografía de las construcciones, se extrajeron los datos manualmente de diversas fuentes de bases de datos, la mayoría abiertas y gratuitas.

En la investigación realizada por Kamara et al. (2019), se extrajo la información para el modelo de resiliencia de manera manual e iterativa.

Por último, en la investigación realizada por Villagra et al. (2017), el cual utiliza el modelo CORE para calcular la resiliencia en las comunidades de zonas costeras; se extrajo la información descargándola en bases de datos municipales, también descargando bases de datos de la Oficina Nacional de Emergencia del Ministerio del Interior (ONEMI) y en la Corporación Nacional Forestal (CONAF), entre otros.

1.3.2. Descripción de la innovación

Se desarrolló un sistema que permite la extracción, transformación y carga de los datos. Este proceso también es conocido como ETL (*Extract, Transform and Load*) en el caso de *Business Intelligence* (BI).

Para esto, se debe comenzar con la premisa de que la información requerida se encuentra dispersa en internet de diferentes formas. Algunas páginas web permiten la extracción de esa información por medio de APIs, otras por medio de descarga de archivos en formato CSV, XLSX, entre otros; además algunas páginas no brindan facilidades para la obtención de su información, por lo que es necesario utilizar técnicas de *web scraping* para obtenerla.

Una vez que la información es extraída, esta debe ser transformada. Para este proceso se debe recordar que cada cálculo varía según el indicador. Por ejemplo en la dimensión social del modelo CORE presentada por Villagra et al. (2017), se puede encontrar un indicador llamado “Tsunami Drills” (Simulacros ante tsunamis) y se calcula con la suma de todos los simulacros realizados entre los años 2010 y 2015. Por lo tanto, los datos extraídos serían los simulacros entre estos años, pero la transformación sería la suma total de todos estos simulacros.

Finalmente, una vez que la información es transformada, esta debe ser almacenada en una

base de datos para luego ser cargada en alguna plataforma. De tal manera que el equipo de investigación pueda acceder a esta fácilmente. La plataforma permite visualizar la información por medio de distintos gráficos y en función del tiempo, junto con información extra como la web de donde fue obtenida y la fecha en la que fue extraída.

1.3.3. Impacto del proyecto

La herramienta desarrollada genera un gran aporte a la investigación de resiliencia comunitaria, especialmente a la investigación del modelo CORE, debido al gran ahorro de tiempo que gana el equipo de investigación, permitiéndoles un conocimiento completo y oportuno de la resiliencia comunitaria en las regiones de Chile involucradas en el proyecto FONDECYT. Esto significa un apoyo directo a la toma de decisiones en cuanto a planificación de las ciudades, integrando la resiliencia como un criterio de análisis de las políticas públicas.

1.4. Objetivos

1.4.1. Objetivo general

Sistematizar el proceso de captura de indicadores cuantitativos sociocomunitarios e institucionales por medio de la extracción de datos de la web para alimentar un modelo de resiliencia comunitaria.

1.4.2. Objetivos específicos

1. Capturar variables para el cálculo de indicadores desde diversas fuentes de información para la dimensión institucional válidas para el modelo de resiliencia.
2. Capturar variables para el cálculo de indicadores desde diversas fuentes de información para la dimensión sociocomunitaria válidas para el modelo de resiliencia.
3. Disponibilizar los indicadores institucionales y sociocomunitarios por medio de una API y analíticas.

2. MARCO TEÓRICO

2.1. Objetivo y pregunta de revisión

Para el desarrollo de esta aplicación se tiene la necesidad de conocer cómo los distintos modelos de resiliencia comunitaria extraen los datos para su cálculo, y a su vez, poder conocer qué tipo de cálculos realizan para obtenerlos. Por esta razón, se decidió dar respuesta a la siguiente pregunta de investigación:

¿Cómo se ha conseguido capturar los datos en los distintos modelos de resiliencia comunitaria en las dimensiones sociocomunitarias e institucionales?

2.2. Método de revisión

Para el desarrollo de esta revisión sistemática, lo primero que se hizo fue utilizar la pregunta de investigación para poder estructurar una cadena de búsqueda a aplicar. Posteriormente se seleccionan los artículos que contengan los criterios de selección dentro de los *abstract*, para luego finalmente analizar y resumir los resultados obtenidos.

2.3. Fuentes y estrategias de búsquedas

La fuente para realizar la búsqueda es la conocida *Web of Science*.

Dado que la mayoría de artículos publicados son en inglés, se decidió hacer el *string* de búsqueda en ese idioma.

Un punto importante en la búsqueda es el cómo las demás investigaciones capturan o procesan los datos. Por esto se optó por *keywords* como *data processing* y *data sources*.

En inglés, el término de “Resiliencia comunitaria” se encuentra en dos términos distintos. Estos son *Community Resilience* que puede verse como una traducción más literal, y también se encuentra *Disaster Resilience*, que en el contexto de resiliencia comunitaria, puede ser interpretado como la resiliencia en caso de desastres.

2.4. Cadena de búsquedas

Con lo anterior, la cadena de búsqueda quedó definida de la siguiente manera:

(“community resilience” OR “disaster resilience”) AND (“data processing” OR “data sources”)

2.5. Criterios de selección

Una vez obtenidos los resultados de búsqueda, se procedió a seleccionar solo aquellos artículos que presenten dentro de su investigación alguna referencia en las dimensiones ya señaladas anteriormente:

- Dimensión sociocomunitaria.
- Dimensión institucional.

2.6. Extracción de la información

Se definió una pauta de extracción de información con la finalidad de poder estructurar mejor la información encontrada. Esta pauta consta de lo siguiente:

- Indicadores de dimensión sociocomunitaria.
- Indicadores de dimensión institucional.
- Método de extracción de dimensiones.
- Tecnología utilizada.
- Método de cálculo de la dimensión.

2.7. Estudios incluidos y excluidos

Primeramente, al realizar la búsqueda con el *string* ya definido, se obtuvo un total de 47 artículos, para luego comenzar a discriminar según el contenido del *abstract*, lo cual da un total de diez artículos para poder resumir y extraer la información pertinente.

Finalmente, de los diez artículos seleccionados, solo siete resultaron ser útiles para la investigación.

Si bien la cantidad de artículos a analizar no es alta, se puede apreciar en la Figura 1 el cómo las investigaciones de resiliencia comunitaria son contemporáneas y han ido en aumento con los años.




Figura 1: Número de artículos por año

2.8. Información extraída general

Toda la información que se encontró relevante en cada artículo seleccionado fue extraída y analizada para posteriormente ser incorporada como ayuda para la elaboración del proyecto de tesis (ver Tabla 1).

Tabla 1: Resumen de la información extraída por artículo

Autor(es)	Indicadores SC	Indicadores Inst.	Método extracción	Tecnología
Cutter et al. (2014)	Social Capital, Population Poverty	Emergency Services	Descarga manual de bases de datos públicas	SPSS

Autor(es)	Indicadores SC	Indicadores Inst.	Método extracción	Tecnología
Villagra et al. (2017)	Civic Organizations, Population Poverty	Tsunami Drills	Descarga manual de bases de datos municipales y gubernamentales	R
Kamara et al. (2019)	Social networks, Community participation	Institutional support	Encuestas y entrevistas	SPSS
Heinzlef et al. (2020)	Social vulnerability	Emergency response	Bases de datos geoespaciales	GIS
Rumson et al. (2020)	Socioeconomic factors	Governance	Bases de datos ambientales	GIS, R
Moghadas et al. (2019)	Social capital	Institutional capacity	Encuestas	SPSS, AHP
Abrash et al. (2021)	Public health outcomes	Emergency preparedness	Revisión sistemática	–
Muhamad et al. (2001)	Exposure elements	Disaster databases	Bases de datos locales	GIS
Wang et al. (2021)	Community engagement	Information dissemination	Twitter API	Python

2.9. Principales hallazgos y factores claves

Uno de los hallazgos que llaman la atención a simple vista es que si bien para este estudio se contempla la dimensión “sociocomunitaria”, en todas las investigaciones analizadas estas aparecen separadas como “Dimensión social” y “Dimensión comunitaria”.

Se realizó un gráfico (ver Figura 2) para apreciar de mejor manera la cantidad de dimensiones especificadas en cada investigación:




Figura 2: Cantidad de veces que se analizó cada dimensión en las investigaciones

De esta forma, se puede ver cómo la dimensión social es la más analizada con cuatro coincidencias en los *papers*, mientras que la menos analizada es la dimensión institucional, con dos coincidencias.

También se agregó la diferencia en la cantidad de indicadores por cada dimensión, como se aprecia en la Figura 3:




Figura 3: Cantidad de indicadores totales por dimensión

En este caso se aprecia que las dimensiones social y física son las que agrupan más indica-

dores en las investigaciones revisadas. Sin embargo, al calcular el promedio de indicadores por cada aparición de dimensión en los artículos (ver Figura 4), se observa que la dimensión institucional, a pesar de ser la menos frecuente, presenta un promedio alto de indicadores cuando aparece.




Figura 4: Promedio de indicadores por aparición de dimensión en los artículos

3. VIABILIDAD DE INDICADORES

En este capítulo se analiza la viabilidad de extracción automática de cada indicador del modelo CORE en las dimensiones sociocomunitaria e institucional. Para cada indicador se identifican las fuentes de datos disponibles, el formato en que se encuentran, la segmentación geográfica y las tareas necesarias para su incorporación al sistema.

Dentro del modelo CORE se especifican los indicadores de la dimensión social que serán objeto de análisis (ver Anexo A). La finalidad de esta búsqueda es analizar cuáles indicadores son viables para realizar la extracción automática de sus datos.

3.1. Population Poverty (PP)

PP hace referencia a la tasa de pobreza de la población. El indicador puede expresarse como porcentaje directo o calcularse a partir de datos en bruto.

Los resultados de la investigación se pueden apreciar en la Tabla 2:

Tabla 2: Resumen de la investigación sobre Population Poverty

Fuente	Tipo dato	Segm.	Formato	Notas
BCN (Biblioteca del Congreso Nacional de Chile, s.f.-a)	Porcentaje y datos en bruto	Comunal	Tabla HTML	Requiere <i>web scraping</i>
Statista (Statista, s.f.)	Porcentaje	Nacional	Tabla	Requiere pago
DataSocial (Ministerio de Desarrollo Social, s.f.)	Datos en bruto	Regional	.xls	Descarga directa

En este caso se observa que la información de la BCN requiere técnicas de *web scraping* para obtener los datos de las tablas HTML, mientras que la fuente de Statista fue descartada por requerir una suscripción pagada. La fuente del Ministerio de Desarrollo Social ofrece la descarga directa en formato XLS.

3.2. Social Capital – Civic Participation (SCCP)

SCCP hace referencia al porcentaje de la población que participa activamente en procesos cívicos (votaciones).

Tabla 3: Resumen de la investigación sobre Civic Participation

Fuente	Tipo dato	Segm.	Formato	Notas
SERVEL (Servicio Electoral de Chile, s.f.)	Datos en bruto	Comunal	.csv	Única fuente identificada

La información es compleja de encontrar debido a que solo se identificó una fuente. El Servicio Electoral de Chile (SERVEL) provee datos en formato CSV que pueden ser descargados directamente.

3.3. Social Capital – Civic Organizations (SCCO)

SCCO hace referencia a la razón de organizaciones civiles por cada 1.000 habitantes por territorio.

Tabla 4: Resumen de la investigación sobre Civic Organizations

Fuente	Tipo dato	Segm.	Formato	Notas
BCN (Biblioteca del Congreso Nacional de Chile, s.f.-b)	Datos en bruto	Comunal	JSON, XLS, CSV, Tabla	Múltiples formatos disponibles

La BCN provee datos de organizaciones comunitarias en múltiples formatos, incluyendo una API JSON que facilita la extracción automática. Cada municipio posee sus propias fuentes de datos, pero la BCN centraliza esta información a nivel comunal.

3.4. Social Capital – Emergency Organizations (SCEO)

SCEO hace referencia a la razón de voluntarios en organizaciones de emergencia por cada 1.000 habitantes.

No se encontró una fuente de datos pública centralizada para este indicador. La información sobre voluntarios en organizaciones de emergencia depende de cada municipalidad y no se encuentra disponible de manera uniforme. Por esta razón, este indicador no pudo ser implementado en el sistema.

3.5. Tsunami Drills

Tsunami Drills hace referencia a la cantidad de simulacros de tsunami realizados en un período de tiempo definido.

Tabla 5: Resumen de la investigación sobre Tsunami Drills

Fuente	Tipo dato	Segm.	Formato	Notas
ONEMI (ONE-MI, s.f.)	Datos en bruto	Nacional	Tabla HTML	Requiere <i>web scraping</i>
MINEDUC (Unidad de Riesgos y Desastres MINE-DUC, 2022)	Datos en bruto	Nacional	Artículo HTML	Requiere <i>web scraping</i>

En este caso se observa que ninguno de los sitios que contienen información sobre los simulacros de tsunami presenta los datos en un formato listo para ser trabajado. La única forma de obtener esta información es por medio de técnicas de *web scraping*.

3.6. Special Needs Population (SNP)

SNP hace referencia al porcentaje de la población que padece algún tipo de discapacidad.

Tabla 6: Resumen de la investigación sobre Special Needs Population

Fuente	Tipo dato	Segm.	Formato	Notas
Obs. Social (Observatorio Social, s.f.)	Porcentaje y datos en bruto	Comunal	.xls, .sav, .dta	Descarga directa
INE (Instituto Nacional de Estadísticas, s.f.-b)	Datos en bruto	Regional	.sav, .dat	Descarga directa
BCN (Biblioteca del Congreso Nacional de Chile, s.f.-c)	Datos en bruto	Comunal	Tabla HTML	Requiere <i>scraping</i> mínimo

La mayoría de los datos se encuentra en un formato listo para ser utilizado y solo en un sitio web es necesario realizar técnicas de *web scraping*.

3.7. Conclusiones del análisis de viabilidad

Las conclusiones obtenidas en este apartado investigativo son múltiples:

En primer lugar se observa que muchos de estos datos requeridos se encuentran en un formato de fácil acceso y listos para ser descargados. En estos casos se puede diseñar el software para que tenga un fuerte énfasis en la descarga de información omitiendo el *scraping* y pasando directamente a ser transformada.

En segundo lugar, la mayoría de los datos se presenta en formato de tabla, por lo que el software podría implementar un mecanismo de detección automática de tablas.

En tercer lugar, los datos que dependen de cada municipalidad requieren una búsqueda específica por sitio web, lo que implica módulos de extracción personalizados.

En cuarto lugar, los formatos no estándar requieren módulos específicos de *scraping* adaptados a la estructura HTML de cada fuente.

4. HERRAMIENTAS DE DESARROLLO

Para la elección de las herramientas de desarrollo a utilizar se consideraron diversos parámetros, entre ellos:

- Herramientas que cuadren con las necesidades que busca resolver el equipo de investigadores.
- La popularidad y uso de las tecnologías. De esta manera se facilita la búsqueda de desarrolladores para mantener y escalar el software a largo plazo.
- Tecnologías con las cuales ya se posee cierta experiencia.

4.1. Lenguaje de programación

El lenguaje de programación elegido para el desarrollo del software es TypeScript. Un lenguaje que permite el desarrollo tanto en el *frontend* como en el *backend*.

TypeScript es un superconjunto de funcionalidades que extienden la sintaxis de Javascript, dotándolo de tipado estático y de objetos basados en clases (TypeScript, s.f.). En resumen, permite aumentar la probabilidad de detectar errores en el código, como también hacer este más legible.

La elección de este lenguaje es debido principalmente a la gran popularidad que posee Javascript, siendo en estos momentos uno de los lenguajes más utilizados a nivel mundial, con un 68,62 % de preferencia según una encuesta realizada en el año 2021 (Stack Overflow, 2021).

4.2. Base de datos

Se decidió utilizar una base de datos no relacional. Específicamente la base de datos MongoDB.

La elección de esta base de datos es debido a la información que se desea almacenar. Los datos deseados no poseen un esquema previamente definido, ya que cada indicador del

modelo CORE posee una estructura distinta. Por lo que utilizar una base de datos relacional (como MySQL o PostgreSQL) aumentaría la complejidad en caso de querer realizar cambios en una etapa avanzada del proyecto.

Adicionalmente, MongoDB permite almacenar documentos con estructuras heterogéneas dentro de una misma colección, lo cual facilita la persistencia de datos provenientes de fuentes diversas sin necesidad de migraciones complejas.

4.3. Entorno de ejecución

El entorno de ejecución predilecto actualmente para el desarrollo de programas con JavaScript/TypeScript es Node.js.

Node.js posee una madurez de más de trece años. Está diseñado para crear aplicaciones escalables y orientado al uso de eventos asíncronos.

Su simplicidad permite desarrollar aplicaciones en poco tiempo, posee un sistema de paquetes (npm) en constante crecimiento que permite a los desarrolladores implementar múltiples herramientas y módulos. Además, al poseer un núcleo liviano, da una ventaja en el tamaño final del software, ya que se utilizan solo las funcionalidades que se deseen implementar.

A continuación se muestra una lista de las librerías principales y secundarias más relevantes que se utilizan, junto con una pequeña descripción.

4.3.1. Librerías principales

- **cheerio**: Permite analizar la estructura de las páginas web permitiendo la extracción y manipulación de los datos. Se utiliza para el *parsing* de HTML en los módulos que requieren *web scraping*.
- **express**: Es actualmente el *framework* más popular de Node.js. Permite el manejo de peticiones HTTP y desarrollo de APIs.
- **mongoose**: Es un ODM que permite escribir consultas y crear esquemas para la base de datos MongoDB. Se utiliza para definir los modelos de datos de cada indicador y gestionar el almacenamiento.
- **request-promise**: Permite hacer llamadas HTTP. Se utiliza para obtener el HTML de una página web o realizar peticiones a APIs externas.

- **puppeteer**: Permite la automatización de un navegador web. Se utiliza para extraer información de páginas que renderizan su contenido mediante Javascript, donde *cheerio* no es suficiente.
- **zod**: Librería de validación y declaración de esquemas. Se utiliza para validar la configuración de los indicadores en tiempo de construcción, asegurando que cada indicador posea los campos requeridos antes de ser registrado en el sistema.
- **pino**: Librería de *logging* de alto rendimiento. Se utiliza como *logger* centralizado del sistema, generando registros tanto en consola (durante el desarrollo) como en archivos de log para auditoría.
- **node-cron**: Permite la programación de tareas periódicas mediante expresiones cron. Se utiliza para automatizar la ejecución de los procesos de extracción según la frecuencia definida para cada indicador.

4.3.2. Librerías secundarias

- **eslint**: Es una herramienta que permite ayudar en la detección de errores de código y mantener este más legible.
- **prettier**: Es una herramienta de formateo de código que asegura un estilo consistente en todo el proyecto.
- **nodemon**: Es una herramienta que permite actualizar automáticamente la ejecución de la aplicación en cuanto detecta cambios en el desarrollo.
- **typescript**: Permite escribir código de TypeScript y transpilarlo a código de Javascript.
- **jest**: *Framework* que permite realizar pruebas unitarias y de integración.

4.4. Contenedores

Para facilitar el despliegue y la reproducibilidad del entorno de desarrollo, se utiliza Docker junto con Docker Compose.

Docker permite crear contenedores aislados que encapsulan la aplicación y sus dependencias, mientras que Docker Compose permite definir y orquestar múltiples servicios de forma declarativa. En el caso de este proyecto, se definen tres servicios: la base de datos MongoDB, una interfaz de administración (Mongo Express) y una herramienta de visualización de datos (Metabase).

Esta decisión permite que cualquier integrante del equipo de investigación pueda levantar el entorno completo con un solo comando, sin necesidad de instalar ni configurar cada servicio de forma manual.

4.5. Visualización de datos

Para la visualización de los datos almacenados se utiliza Metabase, una herramienta de *Business Intelligence* de código abierto que permite crear *dashboards* y consultas sobre bases de datos sin necesidad de escribir código.

Metabase se conecta directamente a MongoDB y permite a los investigadores visualizar los indicadores extraídos por medio de gráficos, tablas y filtros. Los *dashboards* se actualizan automáticamente cada vez que se consultan, reflejando los datos más recientes almacenados en la base de datos.

La elección de Metabase por sobre un *frontend* personalizado (como Angular o React) se debe a que el objetivo principal del proyecto es la extracción y el procesamiento de datos, no la construcción de una interfaz gráfica. Metabase permite cumplir con el objetivo de disponibilizar los datos mediante analíticas sin requerir desarrollo adicional.

4.6. Sistema de control de versiones

Un sistema de control de versiones permite rastrear y gestionar los cambios que son realizados dentro de un código de software. Estas herramientas ayudan a los equipos de desarrollo a gestionar los cambios en el código fuente (Atlassian, s.f.).

En este caso, se optó por utilizar Git. Un sistema de control de versiones creado por Linus Torvalds, el cual está centrado en ser eficiente, confiable y mantenible. Actualmente es utilizado por más de un 93 % de los desarrolladores (Stack Overflow, 2021), convirtiéndose en una de las tecnologías indispensables para el desarrollo de software.

5. DISEÑO DE PROTOTIPO

El tema central que se busca en el desarrollo de la aplicación es realizar de manera correcta la extracción de los indicadores previamente descritos. Para esto, antes de comenzar con la arquitectura final del software, se decidió crear un prototipo encargado de extraer los datos de alguna página en particular que entregue información de alguna dimensión.

El prototipo inicial permitió identificar los desafíos principales del proceso de extracción: cada página web posee su propia estructura HTML, los formatos de datos varían entre fuentes (tablas HTML, archivos CSV, APIs JSON), y la transformación de los datos debe adaptarse a cada caso. Estas observaciones fueron fundamentales para diseñar la arquitectura modular que se describe en el siguiente capítulo.

Los aprendizajes obtenidos del prototipo se pueden resumir en los siguientes puntos:

En primer lugar, la dificultad en el proceso de ETL radica principalmente en la extracción de la información. Cada página web posee su formato HTML definido, por lo que el código escrito para extraer esta información debe adaptarse a cada página web y en ciertos casos a cada dato que se quiere extraer.

En segundo lugar, los datos extraídos se encuentran en un formato genérico que impide su correcto almacenamiento en la base de datos. Por ende deben ser transformados según el tipo de dato esperado (numérico, fecha, texto).

En tercer lugar, el almacenamiento debe contemplar la evitación de duplicados, ya que el sistema ejecutará la extracción de forma periódica y no debe insertar registros que ya existen.

Estos aprendizajes motivaron la decisión de diseñar una arquitectura basada en el patrón Adapter, donde cada etapa del proceso (extracción, transformación, almacenamiento) es intercambiable según la fuente de datos.

A continuación se presentan los artefactos generados durante el desarrollo del prototipo inicial, los cuales sirvieron como base para las decisiones arquitectónicas posteriores.

Se realizó una búsqueda manual en internet para encontrar páginas web que dispusieran de información pertinente a los indicadores. Si bien se encontraron diversas fuentes, la mayoría ya se encontraba en formatos descargables. En la Figura 5 y Figura 6 se muestran ejemplos de la información sociocomunitaria encontrada.

2.1 Tasas de Pobreza año 2017, por Ingresos y Multidimensional

Unidad Territorial	Por Ingresos	Multidimensional
Comuna de Valdivia	7,64	14,07
Región de Los Ríos	12,1	22,2
País	8,6	20,7

Encuesta CASEN 2017, MDS




Figura 5: Información sociocomunitaria sobre tasa de pobreza en el año 2017

2.2 Población carente de servicios básicos y hogares hacinados (% totales, a diciembre 2018)

Unidad Territorial	Totales a Diciembre 2018 (%)	
	Personas en hogares carentes de servicios básico	Hogares hacinados
Comuna de Valdivia	10,7	13,2
Región de Los Ríos	28,4	13,8
Pais	14,1	15,3

Fuente: SIIS-T MDS




Figura 6: Información sociocomunitaria sobre población carente de servicios básicos y hogares hacinados en el año 2018

Para el modelo de la base de datos, se comenzó con la idea de almacenar la información de la página web como tal, para luego ir desglosando la información en modelos más específicos. En la Figura 7 se presenta la *interface* inicial.

```
import ExtractionType from "../enums/ExtractionType";

interface DataInformation{
  url: string,
  date: Date,
  extractionLevel: ExtractionType
}

export default DataInformation;
```

Figura 7: *Interface* para la información de la página web

Una vez obtenida la información base, se continuó con los modelos para cada indicador (ver Figuras 8 y 9).

```
import DataInformation from "../DataInformation";

interface TasaPobreza extends DataInformation{
    unidadTerritorial: string;
    porIngresos: number;
    multidimensional: number;
}

export default TasaPobreza;
```

Figura 8: *Interface* para tasa de pobreza

```
import DataInformation from "../DataInformation";

interface PoblacionCarente extends DataInformation{
    unidadTerritorial: string;
    personasCarentes: number;
    hogaresHacinados: number;
}

export default PoblacionCarente;
```

Figura 9: *Interface* para población carente de servicios básicos y hogares hacinados

Para la extracción, se crearon tres clases (ver Figura 10) encargadas de las distintas etapas del proceso.




Figura 10: Lista de clases utilizadas para la extracción de la información

6. DESARROLLO E IMPLEMENTACIÓN

En este capítulo se describe la arquitectura del software desarrollado, los patrones de diseño utilizados y la implementación de los módulos de extracción de datos. La arquitectura fue diseñada con el objetivo de que agregar un nuevo indicador al sistema requiera el mínimo esfuerzo posible, manteniendo la separación de responsabilidades y la reutilización de componentes.

6.1. Arquitectura general

El sistema se estructura en tres capas principales: el *core*, los módulos y la API. El *core* contiene las clases base, los *adapters* abstractos y la lógica de orquestación del flujo ETL. Los módulos son implementaciones concretas para cada fuente de datos. La API expone los indicadores al exterior mediante *endpoints* HTTP.

Figura 11: Diagrama de arquitectura general del sistema mostrando las tres capas: core, módulos y API

La comunicación entre las capas sigue un flujo unidireccional: la API recibe la solicitud, el *ScraperFactory* obtiene el módulo correspondiente, y el módulo ejecuta el flujo ETL utilizando los *adapters* configurados para ese indicador.

6.2. Patrones de diseño

Se utilizaron diversos patrones de diseño para lograr una arquitectura extensible y con bajo acoplamiento. A continuación se describen los más relevantes.

6.2.1. Patrón Builder

El *IndicatorBuilder* permite configurar cada indicador de forma declarativa, encadenando los métodos de configuración y validando los datos con la librería Zod al momento de construir el indicador. Esto asegura que un indicador no pueda ser registrado en el sistema si le falta información obligatoria como el nombre o la URL de la fuente.

Figura 12: Ejemplo de configuración de un indicador mediante el *IndicatorBuilder*

6.2.2. Patrón Adapter

Cada etapa del flujo ETL se define mediante un *adapter* abstracto que establece la interfaz que deben implementar las clases concretas. Esto permite que un módulo utilice un *adapter* distinto para cada etapa sin modificar la lógica central del sistema. Los *adapters* definidos son:

- **FetchAdapter**: Define cómo se obtienen los datos de la fuente (HTML, JSON, archivo).
- **ParseAdapter**: Define cómo se extrae la información estructurada de los datos crudos.
- **MapperAdapter**: Define cómo se transforman los datos extraídos al formato que se almacena en la base de datos.
- **HashAdapter**: Genera una clave única por registro para evitar duplicados.
- **StorageAdapter**: Controla el almacenamiento de los datos procesados.
- **CalculatorAdapter** (opcional): Calcula un resultado agregado a partir de los datos almacenados y lo persiste en una colección separada.

Figura 13: Diagrama de clases de los *adapters* con sus métodos abstractos

6.2.3. Patrón Factory y Singleton

El *ScraperFactory* es una clase *Singleton* que funciona como registro central de módulos. Cada módulo se registra en el *factory* al iniciar la aplicación, y puede ser obtenido por nombre para ejecutar la extracción de un indicador específico. Esto desacopla la lógica de registro de la lógica de ejecución.

De manera similar, el *CronRegistry* es un *Singleton* que registra tareas programadas para cada indicador según su frecuencia configurada, permitiendo la ejecución automática y periódica del proceso de extracción.

6.2.4. Clase abstracta *ScrapeBase*

Todos los módulos extienden la clase abstracta *ScrapeBase*, la cual implementa el flujo ETL completo. El método `init` orquesta las etapas en el siguiente orden:

1. Se construye la URL reemplazando los parámetros dinámicos (como el año).
2. El *FetchAdapter* obtiene los datos crudos de la fuente.
3. El *ParseAdapter* extrae la información estructurada.
4. El *MapperAdapter* normaliza la estructura de los datos.
5. El *HashAdapter* genera la clave única de cada registro.
6. El *StorageAdapter* almacena los datos en MongoDB, ignorando duplicados.
7. Si existe un *CalculatorAdapter*, se calcula el resultado agregado y se almacena en la colección `indicator-results`, solo si el resultado difiere del último almacenado.

Figura 14: Diagrama de secuencia del flujo ETL completo

6.3. Tipos de conexión implementados

La arquitectura soporta distintos tipos de conexión a fuentes de datos, cada uno implementado como un *FetchAdapter* concreto. Los módulos desarrollados demuestran tres de estos tipos:

Tabla 7: Tipos de conexión implementados en los módulos

FetchAdapter	Tipo de conexión	Módulo
RequestPromiseAdapter	<i>Web scraping</i> de HTML	emergencias-desastres
RequestPromiseAdapter	Extracción de tablas HTML	BCN tasa-pobreza-ingresos
JsonFetchAdapter	Consumo de API JSON	BCN organizaciones-comunitarias

Adicionalmente, el *core* incluye dos *adapters* listos para ser utilizados en futuros módulos:

Tabla 8: *Adapters* disponibles para futuros módulos

FetchAdapter	Tipo de conexión
PuppeteerAdapter	Páginas renderizadas con Javascript
DownloadAdapter	Descarga de archivos (CSV, XLSX)

Estos *adapters* no fueron utilizados en los módulos implementados debido a que las fuentes de datos seleccionadas no lo requerían, pero su existencia demuestra la extensibilidad de la arquitectura.

6.4. Módulos implementados

6.4.1. Módulo emergencias-desastres

Este módulo extrae información sobre simulacros de emergencia desde el sitio web de la Unidad de Riesgos y Desastres del MINEDUC. Dado que los *links* originales de esta página ya no se encuentran disponibles, se accede a las versiones archivadas mediante Wayback Machine (<https://web.archive.org>).

El módulo contiene tres indicadores: simulacros del año 2021, 2022 y 2023. Cada uno utiliza un *ParseAdapter* basado en Cheerio que extrae la fecha, el tipo de evento y la ciudad de cada simulacro a partir de la estructura HTML de la página.

Este módulo además implementa un *CalculatorAdapter* que calcula el total de simulacros y la cantidad por ciudad para cada año, almacenando los resultados en la colección **indicator-results**. Antes de guardar un nuevo resultado, se compara con el último almacenado para evitar registros duplicados cuando los datos de origen no ha cambiado.

Figura 15: Ejemplo de los datos extraídos por el módulo emergencias-desastres en formato JSON

6.4.2. Módulo biblioteca-congreso-nacional

Este módulo contiene dos sub-indicadores que extraen información desde la Biblioteca del Congreso Nacional de Chile (BCN).

El primer sub-indicador, *tasa-pobreza-ingresos*, extrae la tasa de pobreza por ingresos desde la sección de reportes comunales de la BCN. Se utiliza un *ParseAdapter* basado en

Cheerio que identifica la tabla de la sección “2.1 Tasa de Pobreza por ingresos” y extrae las filas correspondientes a la comuna, la región y el país, junto con los valores de las encuestas CASEN 2017 y CASEN 2022.

El segundo sub-indicador, *organizaciones-comunitarias*, extrae la cantidad de organizaciones comunitarias por tipo y año desde la API JSON de estadísticas territoriales de la BCN. Se utiliza un *JsonFetchAdapter* que obtiene el JSON directamente y un *ParseAdapter* que extrae el campo `datosTemaN` que contiene los datos históricos.

Figura 16: Ejemplo de los datos extraídos por cada sub-indicador del módulo BCN

6.5. Manejo de errores

El sistema implementa una jerarquía de errores tipados que permite identificar el origen y el contexto de cada fallo. Los errores se dividen en dos categorías:

- **DomainError:** Errores propios de la lógica del negocio, como un indicador no encontrado (*ParseError*) o un módulo no registrado (*ScraperNotFoundError*).
- **ServiceError:** Errores de servicios externos, como fallos en la conexión HTTP (*FetchError*), en el almacenamiento (*StorageError*) o en la ejecución de tareas programadas (*CronExecutionError*).

Todos los errores heredan de una clase base *BaseError* que incluye un campo de contexto con información adicional. A nivel de la API, un *middleware* centralizado captura estos errores y retorna respuestas JSON con el mensaje correspondiente, evitando que el servidor se detenga ante un fallo.

6.6. Automatización

El *CronRegistry* permite que el sistema ejecute la extracción de indicadores de forma periódica sin intervención manual. Al iniciar la aplicación, el *CronRegistry* recorre todos los módulos registrados y programa una tarea cron para cada indicador que tenga una frecuencia definida.

Las frecuencias se expresan mediante la sintaxis cron estándar y están disponibles como un *enum* predefinido que incluye valores para ejecución diaria, semanal, mensual, anual y

única. La ejecución única se utiliza para fuentes históricas que no se actualizan, como es el caso de los simulacros obtenidos desde Wayback Machine.

6.7. API REST

El sistema expone una API REST que permite consultar los módulos, ejecutar la extracción de indicadores y obtener los resultados calculados. Los *endpoints* implementados son los siguientes:

Tabla 9: *Endpoints* de la API REST

Método	Endpoint	Descripción
GET	/	Lista todos los módulos con sus indicadores
GET	/emergencia-desastres	Lista los indicadores del módulo
GET	/emergencia-desastres/:indicador	Ejecuta la extracción del indicador
GET	/emergencia-desastres/:indicador/resultado	Consulta el último resultado calculado
GET	/biblioteca-congreso-nacional	Lista los indicadores del módulo
GET	/biblioteca-congreso-nacional/:indicador	Ejecuta la extracción del indicador

Cada *endpoint* valida que el indicador solicitado exista antes de ejecutar la extracción. En caso de que no exista, se retorna un error 404 con un mensaje descriptivo.

Figura 17: Colección Bruno con los *endpoints* documentados

6.8. Testing

Se implementaron pruebas automatizadas utilizando el *framework* Jest. Las pruebas se organizan en tres niveles:

En primer lugar, se crearon pruebas unitarias para cada *ParseAdapter*, *MapperAdapter*, *HashAdapter* y *CalculatorAdapter*. Estas pruebas verifican que cada componente funcione de forma aislada con datos de entrada controlados.

En segundo lugar, se crearon pruebas de integración que verifican el flujo ETL completo para cada módulo, desde el *parsing* hasta la generación de la clave única, utilizando datos realistas que simulan la estructura de las fuentes reales.

En tercer lugar, se crearon pruebas de validación que comparan los datos extraídos contra datos de referencia verificados manualmente. Por ejemplo, se verifica que el formato decimal chileno (con coma) sea convertido correctamente al formato numérico estándar (con punto), que las fechas sean parseadas correctamente a partir de los meses en español, y que los nombres de las unidades territoriales se preserven tal como aparecen en la fuente.

El total de pruebas implementadas es de 49, distribuidas en 16 *suites* de pruebas.

6.9. Volatilidad de las fuentes web

Uno de los desafíos más significativos que enfrenta un sistema de extracción de datos de la web es la naturaleza cambiante de las fuentes. A diferencia de una base de datos controlada, las páginas web son mantenidas por terceros que pueden modificar su estructura, migrar su contenido o simplemente dejar de estar disponibles sin previo aviso. Un proceso de *scraping* que funciona hoy no necesariamente funcionará mañana.

Durante el desarrollo de este proyecto se experimentó directamente esta problemática. Los *links* originales del sitio web de la Unidad de Riesgos y Desastres del MINEDUC dejaron de estar disponibles antes de completar la implementación del módulo *emergencias-desastres*. Las páginas que contenían los simulacros de los años 2021, 2022 y 2023 fueron removidas del servidor sin que existiera una redirección o aviso previo. Esto implicó que los datos necesarios para el indicador *Tsunami Drills* ya no eran accesibles desde su fuente original.

Para resolver esta situación, se recurrió a Wayback Machine (<https://web.archive.org>), un servicio de archivo digital de Internet Archive que almacena instantáneas históricas de páginas web. Mediante este servicio se accedió a las versiones archivadas de las páginas del MINEDUC, lo cual permitió completar la extracción de los datos. Sin embargo, esta solución no es generalizable: Wayback Machine no archiva todas las páginas ni con la misma frecuencia, y su disponibilidad depende de un servicio externo.

Este caso evidencia un conjunto de riesgos inherentes a la extracción de datos desde la web que deben ser considerados en el diseño de sistemas ETL de este tipo:

- **Cambios en la estructura HTML:** Una página puede rediseñar su interfaz sin modificar la URL, invalidando los selectores CSS o XPath que el *ParseAdapter* utiliza para extraer los datos. Este tipo de cambio es silencioso, ya que el sistema no recibe un error explícito sino que extrae datos incorrectos o vacíos.

- **Eliminación o migración de contenido:** Las fuentes gubernamentales y académicas reorganizan sus portales periódicamente. URLs que funcionaban durante meses pueden retornar errores 404 o redirigir a páginas genéricas.
- **Cambios en las APIs:** Las APIs públicas pueden modificar sus parámetros, estructura de respuesta o políticas de acceso (como la implementación de autenticación o límites de tasa).
- **Bloqueo de acceso automatizado:** Algunos sitios implementan mecanismos anti-bot como CAPTCHAs, límites por IP o detección de *user-agent*, lo cual puede impedir el acceso al sistema de extracción.

La arquitectura modular basada en *adapters* mitiga parcialmente estos riesgos, ya que un cambio en la estructura de una fuente solo requiere modificar el *ParseAdapter* correspondiente sin afectar al resto del sistema. No obstante, la detección del cambio sigue siendo manual: el sistema no distingue entre una extracción que retorna datos vacíos por un error en la fuente y una fuente que simplemente no tiene datos nuevos.

Como trabajo futuro, se propone implementar mecanismos de monitoreo que alerten cuando una extracción retorna resultados inesperados (cero registros, cambios abruptos en la cantidad de datos o en su estructura), permitiendo una respuesta temprana ante cambios en las fuentes.

7. RESULTADOS

En este capítulo se presentan los resultados obtenidos por el sistema desarrollado, tanto en términos de los datos extraídos como de la validación del correcto funcionamiento de la arquitectura.

7.1. Datos extraídos

7.1.1. Tsunami Drills

El módulo *emergencias-desastres* extrajo un total de 29 registros de simulacros distribuidos en tres años:

Tabla 10: Registros extraídos por indicador de simulacros

Indicador	Registros extraídos
simulacros-2021	9
simulacros-2022	11
simulacros-2023	9

Cada registro contiene la fecha del simulacro, el tipo de evento (sismo, tsunami, incendio forestal, entre otros) y la ciudad o región donde se realizó. Los datos fueron almacenados en la colección **emergencia-desastres** de MongoDB.

Figura 18: Registros extraídos de simulacros-2021 mostrando fecha, tipo y ciudad

7.1.2. Resultados calculados de Tsunami Drills

El *CalculatorAdapter* procesó los datos extraídos y almacenó los resultados en la colección **indicator-results**:

Tabla 11: Resultados calculados por indicador de simulacros

Indicador	Total de simulacros	Ciudades únicas
simulacros-2021	9	9
simulacros-2022	11	11
simulacros-2023	9	9

Estos resultados permiten a los investigadores consultar de forma directa la cantidad de simulacros realizados por año y su distribución geográfica, sin necesidad de procesar los datos crudos manualmente.

Figura 19: *Dashboard* de Metabase con el gráfico de barras de simulacros por año

7.1.3. Tasa de Pobreza por Ingresos

El sub-indicador *tasa-pobreza-ingresos* extrajo tres registros correspondientes a la comuna de Valdivia, la Región de Los Ríos y el país:

Tabla 12: Datos extraídos de tasa de pobreza por ingresos

Unidad Territorial	CASEN 2017	CASEN 2022
Comuna de Valdivia	7,6 %	9,8 %
Región de Los Ríos	12,1 %	12,2 %
País	8,6 %	10,8 %

Los porcentajes fueron convertidos correctamente del formato decimal chileno (con coma) al formato numérico estándar (con punto), permitiendo su uso directo en cálculos posteriores.

Figura 20: *Dashboard* de Metabase con el gráfico comparativo de pobreza CASEN 2017 vs CASEN 2022

7.1.4. Organizaciones Comunitarias

El sub-indicador *organizaciones-comunitarias* extrajo 17 registros correspondientes a los años 2008 a 2024 para la comuna de Valdivia. Cada registro contiene la cantidad de once

tipos de organizaciones comunitarias: juntas de vecinos, clubes deportivos, centros de madres, centros culturales, centros del adulto mayor, uniones comunales, centros de padres y apoderados, compañías de bomberos, entre otros.

Figura 21: *Dashboard* de Metabase con el gráfico de línea temporal de organizaciones comunitarias

7.2. Validación de la extracción

Para validar que los datos extraídos por el sistema son correctos, se realizó una comparación con datos obtenidos de forma manual desde las mismas fuentes.

En el caso de la tasa de pobreza, se verificó manualmente que los valores presentados en la tabla de la BCN coincidieran con los valores almacenados en la base de datos. La conversión del formato decimal chileno fue validada en las pruebas automatizadas.

En el caso de los simulacros, se verificó que las fechas extraídas correspondieran a los meses correctos, considerando que la fuente utiliza abreviaciones en español (Ene, Feb, Mar, etc.). Las pruebas automatizadas validan que cada abreviación sea convertida al índice de mes correcto.

En el caso de las organizaciones comunitarias, se verificó que la suma total de organizaciones reportada por la BCN coincidiera con la suma de los tipos individuales extraídos por el sistema.

7.3. Evitación de duplicados

El sistema fue ejecutado múltiples veces sobre las mismas fuentes de datos para verificar que los mecanismos de evitación de duplicados funcionaran correctamente. El *HashAdapter* genera una clave única para cada registro (basada en la fecha y ciudad para simulacros, en la unidad territorial para pobreza, y en el año para organizaciones), y los esquemas de MongoDB declaran este campo como único. En cada ejecución posterior a la primera, el sistema detectó los duplicados y los ignoró sin generar errores.

De manera similar, el *CalculatorAdapter* comparó los resultados calculados con el último resultado almacenado y no creó registros nuevos cuando los datos de origen no había cambiado.

7.4. Ejecución automatizada

Se verificó que el *CronRegistry* programe correctamente las tareas de extracción. Los indicadores de la BCN fueron configurados con frecuencia anual (expresión cron 0 0 1 1 *) y los simulacros con frecuencia única (sin expresión cron), lo cual es coherente con la naturaleza de cada fuente: los datos de la BCN se actualizan periódicamente, mientras que los datos de Wayback Machine son estáticos.

8. CONCLUSIONES

8.1. Conclusiones generales

El presente proyecto logró desarrollar un sistema de extracción, transformación y carga de datos que sistematiza el proceso de captura de indicadores para el modelo CORE de resiliencia comunitaria. La arquitectura modular basada en *adapters* permite agregar nuevos indicadores y fuentes de datos sin modificar la lógica central del sistema, lo cual constituye el principal aporte técnico del trabajo.

El sistema demostró ser funcional para tres tipos de fuentes de datos distintas (*web scraping* de HTML, extracción de tablas y consumo de APIs JSON), extrayendo y almacenando datos de cinco indicadores distribuidos en dos módulos. Además, la validación realizada confirmó que los datos extraídos coinciden con los obtenidos de forma manual, y que los mecanismos de evitación de duplicados operan correctamente ante ejecuciones repetidas.

8.2. Conclusiones por objetivo

8.2.1. Objetivo Específico 1

El indicador *Tsunami Drills* fue implementado exitosamente, extrayendo un total de 29 registros de simulacros de emergencia entre los años 2021 y 2023 desde el sitio web del MINEDUC. El *CalculatorAdapter* permitió calcular automáticamente el total de simulacros y su distribución geográfica.

El indicador *Emergency Organizations* (SCEO) no pudo ser implementado debido a la inexistencia de una fuente de datos pública que centralice esta información. Como se documentó en el capítulo de viabilidad de indicadores, estos datos dependen de cada municipalidad y no se encuentran disponibles en una plataforma accesible desde la web. Esta limitación es inherente al dominio de la extracción de datos web: el sistema solo puede capturar información de fuentes que existen y son accesibles. La arquitectura desarrollada permite incorporar este indicador en el futuro si se identifica una fuente viable.

8.2.2. Objetivo Específico 2

Se implementaron dos indicadores: *Population Poverty* mediante la extracción de la tasa de pobreza por ingresos desde la BCN, y *Civic Organizations* mediante la extracción de organizaciones comunitarias desde la API JSON de la BCN.

Los indicadores *Civic Participation* (SCCP) y *Special Needs Population* (SNP) no fueron implementados dentro del alcance de este proyecto, aunque se identificaron sus fuentes de datos en el capítulo de viabilidad (SERVEL para SCCP, CASEN e INE (Instituto Nacional de Estadísticas, s.f.-a) para SNP). Dado que estas fuentes ofrecen descargas directas en formato CSV y XLSX, la arquitectura desarrollada ya los soporta mediante el *DownloadAdapter* existente, lo cual facilita su incorporación sin modificaciones al *core* del sistema.

8.2.3. Objetivo Específico 3

Se logró disponibilizar los indicadores por medio de una API REST y analíticas. La API permite listar los módulos e indicadores disponibles, ejecutar la extracción de datos y consultar los resultados calculados. Los datos almacenados en MongoDB son visualizados mediante *dashboards* en Metabase, los cuales se actualizan automáticamente a medida que se pueblan las colecciones.

8.3. Limitaciones

Durante el desarrollo del proyecto se identificaron las siguientes limitaciones:

En primer lugar, la volatilidad de las fuentes web representó el mayor desafío del proyecto. Como se detalló en la sección 6.9, los *links* originales del sitio web del MINEDUC dejaron de estar disponibles durante el transcurso del desarrollo, obligando a recurrir a Wayback Machine para acceder a versiones archivadas. Este no es un caso aislado: la naturaleza cambiante de la web implica que un proceso de *scraping* que funciona hoy puede dejar de funcionar en cualquier momento debido a rediseños de páginas, migraciones de contenido o cambios en las políticas de acceso. Esta realidad debe ser considerada como una restricción fundamental en todo sistema que dependa de la extracción automatizada de datos desde fuentes web no controladas.

En segundo lugar, el indicador SCEO (*Emergency Organizations*) no pudo ser implementado debido a la ausencia de una fuente de datos pública centralizada. La información sobre voluntarios en organizaciones de emergencia depende de cada municipalidad y no se encuentra disponible de manera uniforme.

En tercer lugar, la plataforma Statista fue descartada como fuente para el indicador de pobreza debido a que requiere un pago o suscripción para acceder a sus datos.

En cuarto lugar, la librería *request-promise* utilizada para las peticiones HTTP se encuentra deprecada. Si bien esto no afecta el funcionamiento actual del sistema, representa una deuda técnica que debe ser abordada en futuras iteraciones.

8.4. Trabajo futuro

Con base en las limitaciones identificadas y la extensibilidad de la arquitectura, se proponen las siguientes líneas de trabajo futuro:

- Implementar los indicadores pendientes (SCCP, SNP) utilizando el *DownloadAdapter* ya disponible en el *core* para la descarga de archivos CSV y XLSX.
- Migrar la librería *request-promise* a *fetch* nativo o *axios* para resolver la deuda técnica asociada a la dependencia deprecada.
- Agregar un mecanismo de *retry* con *backoff* exponencial en los *FetchAdapters* para manejar de forma robusta los fallos temporales en las fuentes externas.
- Explorar un enfoque híbrido que combine la arquitectura modular con modelos de lenguaje (LLM) como mecanismo de *fallback* para el *parsing* adaptativo cuando una fuente cambia su estructura HTML.
- Generalizar los módulos de la BCN para soportar múltiples comunas mediante parámetros dinámicos en la URL.
- Desarrollar un *frontend* personalizado como alternativa a Metabase para casos donde se requiera mayor control sobre la visualización de los datos.

REFERENCIAS

- Abrash, W. A., Marr, J., Cahillane, M. J., & Bush, K. (2021). Building Community Resilience to Disasters: A Review of Interventions to Improve and Measure Public Health Outcomes in the Northeastern United States.
- Atlassian. (s.f.). *What is Version Control*. Consultado el 1 de junio de 2022, desde <https://www.atlassian.com/es/git/tutorials/what-is-version-control>
- Biblioteca del Congreso Nacional de Chile. (s.f.-a). *Reportes Comunales — Valdivia*. Consultado el 4 de julio de 2022, desde https://www.bcn.cl/siit/reportescomunales/comunas_v.html?anno=2020&idcom=14101
- Biblioteca del Congreso Nacional de Chile. (s.f.-b). *SIIT Estadísticas Territoriales — Organizaciones Comunitarias*. Consultado el 26 de agosto de 2022, desde <https://www.bcn.cl/siit/estadisticasterritoriales/tema?id=137>
- Biblioteca del Congreso Nacional de Chile. (s.f.-c). *SIIT Estadísticas Territoriales — Prevalencia de Personas con Discapacidad*. Consultado el 2 de septiembre de 2022, desde <https://www.bcn.cl/siit/estadisticasterritoriales/tema?id=196>
- Cutter, S. L., Ash, K. D., & Emrich, C. T. (2014). The Geographies of Community Disaster Resilience. *Global Environmental Change*.
- Heinzlef, C., Becue, V., & Serre, D. (2020). A Spatial Decision Support System for Enhancing Resilience to Floods: Bridging Resilience Modeling and Geovisualization Techniques.
- Instituto Nacional de Estadísticas. (s.f.-a). *Censo de Población y Vivienda 2017*. Consultado el 26 de agosto de 2022, desde <https://www.ine.cl/estadisticas/sociales/censos-de-poblacion-y-vivienda/censo-de-poblacion-y-vivienda>
- Instituto Nacional de Estadísticas. (s.f.-b). *Discapacidad*. Consultado el 2 de septiembre de 2022, desde <https://www.ine.cl/estadisticas/sociales/condiciones-de-vida-y-cultura/discapacidad>
- Kamara, J. K., Agho, K., & Renzaho, A. M. N. (2019). Understanding Disaster Resilience in Communities Affected by Recurrent Drought in Lesotho and Swaziland — A Qualitative Study. *PLoS ONE*.
- Maguire, B., & Cartwright, S. (2008). Assessing a Community's Capacity to Manage Change: A Resilience Approach to Social Assessment.
- Ministerio de Desarrollo Social. (s.f.). *DataSocial — Catálogo de Dimensiones*. Consultado el 26 de agosto de 2022, desde <https://datasocial.ministeriodesarrollosocial.gob.cl/portalDataSocial/catalogoDimension/47>
- Moghadas, M., Asadzadeh, A., Vafeidis, A., Fekete, A., & Koetter, T. (2019). A Multi-Criteria Approach for Assessing Urban Flood Resilience in Tehran, Iran.
- Muhamad, N., Arshad, S. H. M., & Pereira, J. J. (2001). Exposure Elements in Disaster Databases and Availability for Local Scale Application: Case Study of Kuala Lumpur, Malaysia.

- Observatorio Social. (s.f.). *Encuesta CASEN 2017*. Consultado el 26 de agosto de 2022, desde <http://observatorio.ministeriodesarrollosocial.gob.cl/encuesta-casen-2017>
- ONEMI. (s.f.). *Chile Preparado — Simulacros*. Consultado el 2 de septiembre de 2022, desde <http://chile-preparado.onemi.gov.cl/simulacros/>
- Rumson, A. G., García, A. P., & Hallett, S. H. (2020). The Role of Data Within Coastal Resilience Assessments: An East Anglia, UK, Case Study.
- Servicio Electoral de Chile. (s.f.). *Estadísticas del Registro Electoral*. Consultado el 26 de agosto de 2022, desde <https://www.servel.cl/estadisticas-2/>
- Stack Overflow. (2021). *Stack Overflow Developer Survey 2021*. Consultado el 31 de mayo de 2022, desde <https://insights.stackoverflow.com/survey/2021>
- Statista. (s.f.). *Porcentaje de Personas en Situación de Pobreza en Chile de 2003 a 2020*. Consultado el 26 de agosto de 2022, desde <https://es.statista.com/estadisticas/1274561/porcentaje-de-la-poblacion-chilena-bajo-la-linea-de-pobreza/>
- TypeScript. (s.f.). *TypeScript: JavaScript With Syntax For Types*. Consultado el 31 de mayo de 2022, desde <https://www.typescriptlang.org/docs/handbook/typescript-from-scratch.html>
- Unidad de Riesgos y Desastres MINEDUC. (2022). *Simulacros 2022*. Consultado el 1 de septiembre de 2022, desde <https://emergenciaydesastres.mineduc.cl/simulacros-2022/>
- Villagra, P., Herrmann, M. G., Quintana, C., & Sepúlveda, R. D. (2017). Community Resilience to Tsunamis Along the Southeastern Pacific: A Multivariate Approach Incorporating Physical, Environmental, and Social Indicators.
- Wang, K., Lam, N. S. N., Zou, L., & Mihunov, V. (2021). Twitter Use in Hurricane Isaac and Its Implications for Disaster Resilience.

A. INDICADORES DEL MODELO CORE

Table 2 continued

Dimension	Indicator	Calculation description	Relation to resilience	References	Data source
Social	Population Poverty (PP)	Percentage	(-) >Value < resilience	Cutter et al. (2014)	National Socioeconomic Survey (CASEN 2009, 2011), National Institute of Statistics (INE 2002)
	Social Capital-Civic Participation (SCCP)	Percentage	(+) >Value > resilience	Cervero and Duncan (2003), Chou et al. (2013)	National Socioeconomic Survey (CASEN 2009)
	Social Capital-Civic Organizations (SCCO)	Number of civic organization/1000	(+) >Value > resilience	Cutter et al. (2014)	Local Municipalities
	Social Capital-Emergency Organizations (SCEO)	Number of volunteers/1000	(+) >Value > resilience	Cutter et al. (2014)	Local Municipalities
	Tsunami Drills (TD)	Number between 2010 and 2015	(+) >Value > resilience	Chou et al. (2013), The Sphere Project (2004)	National Emergency Office (ONEMI 2015)
	Special Needs Population (SNP)	Percentage	(-) >Value < resilience	Cutter et al. (2014)	National Socioeconomic Survey (CASEN 2013)

Figura 22: Indicadores de la dimensión social del modelo CORE